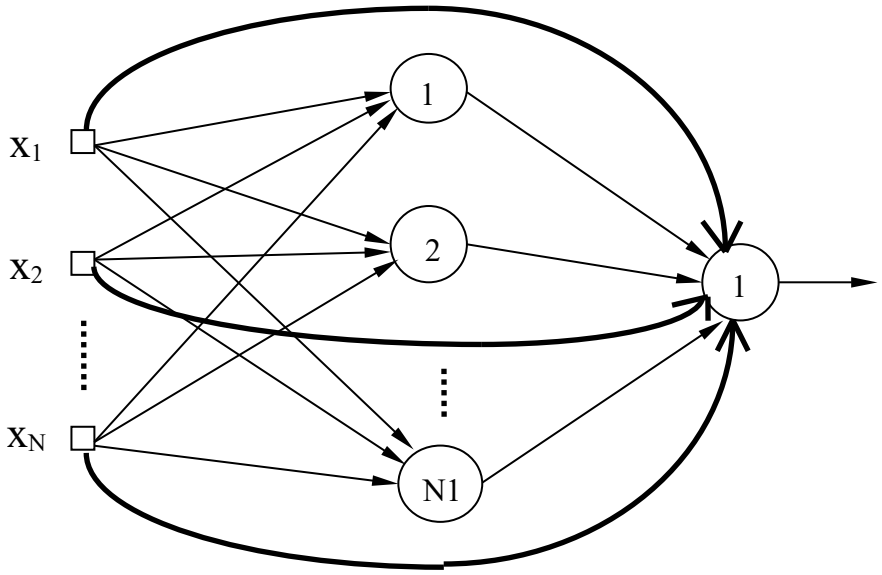
CEFET-MG	**Centro Federal de Educação Tecnológica de Minas Gerais** ***Campus VIII – Varginha*** **Bacharelado em Sistemas de Informação**			
Disciplina Lab. Inteligência Artificial	**TRABALHO**	***Professor*** Lázaro Eduardo da Silva	***Valor*** 100%	***Nota***
Data: 08/10/2026	***Aluno(a):*** Caio Magalhães Fonseca Arantes			

Visando uma aplicação específica, a equipe de engenheiros e cientistas de uma instituição projetou uma rede neural artificial do tipo perceptron multicamadas, constituída de três camadas, cuja topologia da mesma está ilustrada na figura abaixo.



As informações referentes à topologia da rede estão como se segue:

Camada de Entrada → Constituída de "N" sinais de entrada (X_1 , X_2 , ..., X_N).
Camada Neural Escondida → Constituída de "N1" neurônios.
Camada Neural de Saída → Constituída de apenas 1 neurônio.
Conjunto de Padrões de Treinamento → Constituído de "P" padrões.

Demonstre de forma detalhada como será a seqüência e o ajuste das matrizes de pesos entre cada uma das camadas quando se utiliza o algoritmo de aprendizagem "Backpropagation".

Utilize a seguinte convenção:

Matriz **W1** → Matriz de pesos entre a 1ª e 2ª camada.
Matriz **W2** → Matriz de pesos entre a 2ª e 3ª camada.
Matriz **W3** → Matriz de pesos entre a 1ª e 3ª camada.

Centro Federal de Educação Tecnológica de Minas Gerais — CEFET-MG
Campus VIII – Varginha | Bacharelado em Sistemas de Informação
Disciplina: Laboratório de Inteligência Artificial — Prof. Lázaro Eduardo da Silva
Aluno: Caio Magalhães Fonseca Arantes | Data: 08/10/2026

RESOLUÇÃO — EXERCÍCIO 1: DEMONSTRAÇÃO DO BACKPROPAGATION

Ajuste das Matrizes de Pesos (W1, W2 e W3) em Perceptron Multicamadas com Conexões Diretas

1. Topologia da Rede e Convenção das Matrizes

A rede neural possui **três camadas** com uma topologia diferencial: conexões convencionais camada a camada e conexões diretas entre a camada de entrada e a camada de saída.

Camada / Elemento	Constituição / Dimensão	Convenção Adotada
Camada de Entrada	N sinais de entrada + bias $x_0 = -1$	$\mathbf{x = [x_0, x_1, ..., x_N]^T}$
Camada Oculta	N_1 neurônios + bias $z_0 = -1$	$\mathbf{z = [z_0, z_1, ..., z_{N1}]^T}$
Camada de Saída	1 neurônio de saída linear ou sigmoide	$\mathbf{y = f(u_{saída})}$
Matriz W1	Entrada → Camada Oculta: $N_1 \times (N+1)$	$\mathbf{Pesos\ w1_{ji}}$
Matriz W2	Camada Oculta → Saída: $1 \times (N_1+1)$	$\mathbf{Pesos\ w2_{1j}}$
Matriz W3	Conexão DIRETA Entrada → Saída: $1 \times (N+1)$	$\mathbf{Pesos\ w3_{1i}}$

2. Passo Forward (Propagação Direta dos Sinais)

2.1. Potencial e Saída na Camada Oculta:

Para cada neurônio oculto j (j = 1, ..., N_1), o potencial de ativação u_j é dado por:

$$\mathbf{u_j = \sum_{i=0}^{N} w1_{ji} \cdot x_i = w1_{j0} \cdot x_0 + \sum_{i=1}^{N} w1_{ji} \cdot x_i}$$

Aplicando a função de ativação logística sigmoide g(·):

$$\mathbf{z_j = g(u_j)}, \quad \text{com} \quad z_0 = -1 \text{ (bias da camada oculta).}$$

2.2. Potencial e Saída no Neurônio de Saída:

O neurônio de saída recebe simultaneamente a combinação das saídas ocultas via W2 e a combinação direta das entradas via W3:

$$\mathbf{u_{saída} = \sum_{j=0}^{N1} w2_{1j} \cdot z_j + \sum_{i=0}^{N} w3_{1i} \cdot x_i}$$

A saída final calculada pela rede é:

$$\mathbf{y = f(u_{saída})}$$

3. Função de Custo e Regra do Gradiente Descendente

Para cada padrão de treinamento com valor desejado d, define-se o erro instantâneo e a energia do erro:

$$\mathbf{e = d - y}$$

$$\mathbf{E = (1/2) \cdot e^2 = (1/2) \cdot (d - y)^2}$$

A atualização dos pesos segue a regra do gradiente descendente:

$$\mathbf{\Delta w = -\eta \cdot (\partial E / \partial w)}, \quad \text{onde } \eta > 0 \text{ é a taxa de aprendizagem.}$$

Centro Federal de Educação Tecnológica de Minas Gerais — CEFET-MG
Campus VIII – Varginha | Bacharelado em Sistemas de Informação
Disciplina: Laboratório de Inteligência Artificial — Prof. Lázaro Eduardo da Silva
Aluno: Caio Magalhães Fonseca Arantes | Data: 08/10/2026

4. Passo Backward — Dedução Analítica via Regra da Cadeia

4.1. Gradiente Local da Camada de Saída ($\delta_{saída}$)

Pela Regra da Cadeia, a derivada parcial de E em relação ao potencial $u_{saída}$ é:

$$\partial E / \partial u_{saída} = (\partial E / \partial e) \cdot (\partial e / \partial y) \cdot (\partial y / \partial u_{saída})$$

Calculando cada termo:

- $\partial E / \partial e = e$
- $\partial e / \partial y = -1$
- $\partial y / \partial u_{saída} = f'(u_{saída})$

Portanto: $\partial E / \partial u_{saída} = (e) \cdot (-1) \cdot f'(u_{saída}) = -(d - y) \cdot f'(u_{saída})$.

Definindo o **gradiente local da camada de saída** $\delta_{saída}$ como o negativo desta derivada:

$$\delta_{saída} \equiv -(\partial E / \partial u_{saída}) = (d - y) \cdot f'(u_{saída})$$

4.2. Ajuste da Matriz W2 (Camada Oculta → Camada de Saída)

Para cada peso $w2_{1j}$ conectando o neurônio oculto z_j ao neurônio de saída (j = 0, ..., N_1):

$$\partial E / \partial w2_{1j} = (\partial E / \partial u_{saída}) \cdot (\partial u_{saída} / \partial w2_{1j}) = -\delta_{saída} \cdot z_j$$

Aplicando a regra do gradiente descendente:

$$\Delta w2_{1j} = -\eta \cdot (\partial E / \partial w2_{1j}) = \eta \cdot \delta_{saída} \cdot z_j$$

$$w2_{1j}^{(novo)} = w2_{1j}^{(atual)} + \eta \cdot \delta_{saída} \cdot z_j, \quad \text{para todo } j \in \{0, 1, ..., N_1\}.$$

4.3. Ajuste da Matriz W3 (Conexão DIRETA: Entrada → Saída)

Para cada peso $w3_{1i}$ conectando a entrada x_i diretamente ao neurônio de saída (i = 0, ..., N):

$$\partial E / \partial w3_{1i} = (\partial E / \partial u_{saída}) \cdot (\partial u_{saída} / \partial w3_{1i}) = -\delta_{saída} \cdot x_i$$

Aplicando a regra do gradiente descendente:

$$\Delta w3_{1i} = -\eta \cdot (\partial E / \partial w3_{1i}) = \eta \cdot \delta_{saída} \cdot x_i$$

$$w3_{1i}^{(novo)} = w3_{1i}^{(atual)} + \eta \cdot \delta_{saída} \cdot x_i, \quad \text{para todo } i \in \{0, 1, ..., N\}.$$

Interpretação: As conexões diretas atuam como um atalho linear em paralelo à sub-rede oculta, capturando diretamente componentes afins sem sobrecarregar a camada intermediária.

4.4. Ajuste da Matriz W1 (Entrada → Camada Oculta)

Para cada peso $w1_{ji}$ conectando a entrada x_i ao neurônio oculto j (j = 1, ..., N_1; i = 0, ..., N):

$$\partial E / \partial w1_{ji} = (\partial E / \partial u_{saída}) \cdot (\partial u_{saída} / \partial z_j) \cdot (\partial z_j / \partial u_j) \cdot (\partial u_j / \partial w1_{ji})$$

Substituindo cada termo:

- $\partial E / \partial u_{saída} = -\delta_{saída}$
- $\partial u_{saída} / \partial z_j = w2_{1j}$
- $\partial z_j / \partial u_j = g'(u_j) = z_j(1 - z_j)$
- $\partial u_j / \partial w1_{ji} = x_i$

Agrupando os termos e definindo o **gradiente local do neurônio oculto j** (δ_j):

$$\delta_j \equiv -(\partial E / \partial u_j) = \delta_{saída} \cdot w2_{1j} \cdot g'(u_j) = \delta_{saída} \cdot w2_{1j} \cdot z_j(1 - z_j)$$

Assim, a regra de atualização dos pesos da camada oculta é:

$$\Delta w1_{ji} = -\eta \cdot (\partial E / \partial w1_{ji}) = \eta \cdot \delta_j \cdot x_i$$

$$w1_{ji}^{(novo)} = w1_{ji}^{(atual)} + \eta \cdot \delta_j \cdot x_i, \quad \text{para todo } j \in \{1, ..., N_1\} \text{ e } i \in \{0, ..., N\}.$$

5. Síntese das Equações de Ajuste Sináptico

Matriz	Conexão	Gradiente Local	Equação de Ajuste Sináptico (Δw)
W2	Oculta → Saída	$\delta_{saída} = (d - y) \cdot f'(u_{saída})$	$\Delta w2_{1j} = \eta \cdot \delta_{saída} \cdot z_j$
W3	Entrada → Saída (Direta)	$\delta_{saída} = (d - y) \cdot f'(u_{saída})$	$\Delta w3_{1i} = \eta \cdot \delta_{saída} \cdot x_i$
W1	Entrada → Oculta	$\delta_j = \delta_{saída} \cdot w2_{1j} \cdot z_j(1 - z_j)$	$\Delta w1_{ji} = \eta \cdot \delta_j \cdot x_i$