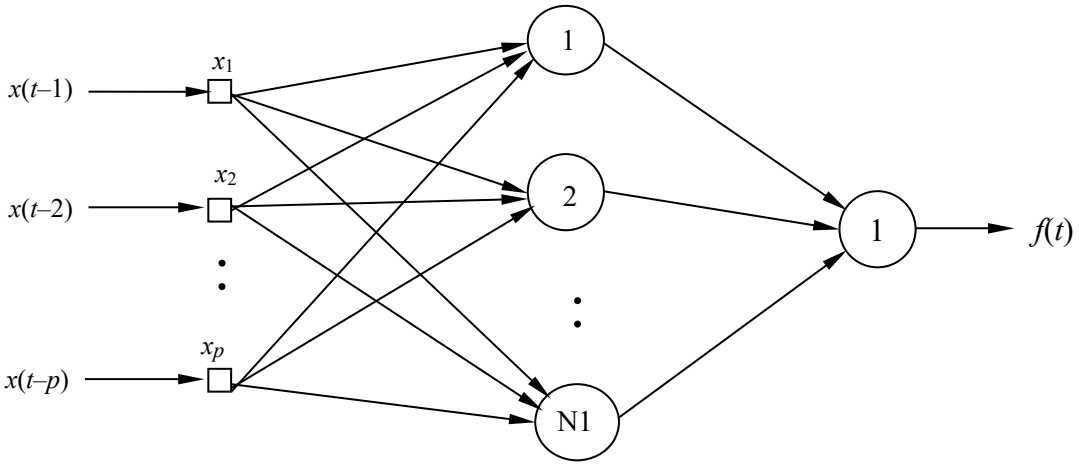
CEFET-MG	**Centro Federal de Educação Tecnológica de Minas Gerais** ***Campus VIII – Varginha*** **Bacharelado em Sistemas de Informação**			
Disciplina Lab. Inteligência Artificial	**TRABALHO**	***Professor*** Lázaro Eduardo da Silva	***Valor*** 100%	***Nota***
Data: 14/10/2026	***Aluno(a):*** Caio Magalhães Fonseca Arantes			

O preço de uma determinada mercadoria disposta para ser comercializada no mercado financeiro de ações possui um histórico de variação de valor conforme mostrado na tabela apresentada no Apêndice.

Um pool de pesquisadores estará tentando aplicar redes neurais para tentar prever o comportamento futuro deste processo. Assim, pretende-se utilizar uma arquitetura perceptron multicamadas, com topologia "Time Delay" (TDNN), conforme mostrado na figura abaixo:



As topologias candidatas para serem aplicadas no mapeamento do problema acima são especificadas como segue:

Rede 1 → 05 entradas (p = 05) com N1 = 10
Rede 2 → 10 entradas (p = 10) com N1 = 15
Rede 3 → 15 entradas (p = 15) com N1 = 25

Utilizando o algoritmo de aprendizagem *backpropagation com momentum* e os dados de treinamento apresentados no Anexo, realize as seguintes atividades:

1. Execute 3 treinamentos para cada rede perceptron acima inicializando as matrizes de pesos em cada treinamento com valores aleatórios entre 0 e 1. Se for o caso, reinicie o gerador de números aleatórios em cada treinamento de tal forma que os elementos das matrizes de pesos iniciais não sejam os mesmos. Utilize a função de ativação logística (*sigmoid*) para todos os neurônios, taxa de aprendizado $\eta = 0.1$, fator de momentum $\alpha = 0.8$ e precisão $\varepsilon = 0.5 \times 10^{-6}$.

2. Registre os resultados finais desses 3 treinamentos para cada uma das três topologias de rede na tabela a seguir:

Treinamento	**Rede 1**		**Rede 2**		**Rede 3**	
	EQM	Épocas	EQM	Épocas	EQM	Épocas
1º (T1)	0.001085	922	0.000822	353	0.000760	563
2º (T2)	0.000672	1486	0.000855	341	0.000385	1125
3º (T3)	0.001136	992	0.000334	943	0.000475	824

3. Para todos os treinamentos efetuados no item 2, faça a validação da rede em relação aos valores desejados apresentados na tabela abaixo. Forneça para cada treinamento o erro relativo médio entre os valores desejados e os valores fornecidos pela rede em relação a todos os padrões de teste. Obtenha também a respectiva variância.

		Rede 1			**Rede 2**			**Rede 3**		
Amostra	$f(t)$	(T1)	(T2)	(T3)	(T1)	(T2)	(T3)	(T1)	(T2)	(T3)
$t = 101$	0.4173	0.4486	0.4549	0.4623	0.4513	0.4506	0.4122	0.4401	0.4231	0.4347
$t = 102$	0.0062	0.0234	0.0053	0.0264	0.0111	0.0146	0.0103	0.0127	0.0089	0.0103
$t = 103$	0.3387	0.3887	0.3919	0.3976	0.3682	0.3725	0.3599	0.3950	0.3806	0.3827
$t = 104$	0.1886	0.2112	0.2043	0.2363	0.1256	0.1295	0.1565	0.1336	0.1347	0.1460
$t = 105$	0.7418	0.7330	0.7548	0.7147	0.7434	0.7440	0.7195	0.7647	0.7513	0.7557
$t = 106$	0.3138	0.2065	0.2359	0.1903	0.2316	0.2235	0.2766	0.2304	0.2708	0.2493
$t = 107$	0.4466	0.4306	0.4239	0.4222	0.4621	0.4673	0.4468	0.4554	0.4388	0.4353
$t = 108$	0.0835	0.0788	0.0451	0.0878	0.1209	0.1201	0.1003	0.0930	0.0998	0.0927
$t = 109$	0.1930	0.2159	0.2122	0.2072	0.2214	0.2172	0.2084	0.1979	0.1978	0.2005
$t = 110$	0.3807	0.3100	0.3577	0.3027	0.4650	0.4648	0.4480	0.4452	0.4382	0.4273
$t = 111$	0.5438	0.5431	0.5373	0.5556	0.5515	0.5544	0.5568	0.5341	0.5404	0.5411
$t = 112$	0.5897	0.6655	0.6386	0.6460	0.6125	0.6206	0.5830	0.6408	0.5996	0.6231
$t = 113$	0.3536	0.3713	0.3675	0.3739	0.3006	0.2990	0.3394	0.3367	0.3559	0.3560
$t = 114$	0.2210	0.1929	0.1899	0.2026	0.2392	0.2410	0.2234	0.2458	0.2170	0.2288
$t = 115$	0.0631	0.1476	0.1237	0.1459	0.0484	0.0464	0.0527	0.0612	0.0685	0.0541
$t = 116$	0.4499	0.4297	0.4452	0.4254	0.4064	0.4057	0.4193	0.4246	0.4243	0.4314
$t = 117$	0.2564	0.2452	0.2273	0.2491	0.2807	0.2802	0.2371	0.2651	0.2456	0.2434
$t = 118$	0.7642	0.7803	0.7603	0.7704	0.7636	0.7591	0.7847	0.7437	0.7670	0.7525
$t = 119$	0.1411	0.1361	0.1500	0.1334	0.1479	0.1467	0.1256	0.1557	0.1368	0.1412
$t = 120$	0.3626	0.3208	0.3473	0.3172	0.3560	0.3558	0.3592	0.3458	0.3573	0.3528
Erro Relativo Médio:		**28.89%**	**14.38%**	**32.27%**	**15.90%**	**19.03%**	**10.29%**	**13.75%**	**8.42%**	**9.83%**
Variância:		**4056.4**	**452.56**	**5321.5**	**342.80**	**844.76**	**206.12**	**498.07**	**122.77**	**211.69**

4. Para cada uma das topologias apresentadas na tabela acima, considerando ainda o melhor treinamento {T1, T2 ou T3} realizado em cada uma delas, trace o gráfico dos valores de erro quadrático médio (EQM) em função de cada época de treinamento. Imprima os três gráficos numa mesma folha de modo não superpostos.

5. Para cada uma das topologias apresentadas na tabela acima, considerando ainda o melhor treinamento {T1, T2 ou T3} realizado em cada uma delas, trace o gráfico dos valores desejados e dos valores estimados pela respectiva rede em função do domínio de estimação considerado (t=101..120). Imprima os três gráficos numa mesma folha de modo não superpostos.

6. Baseado nas análises dos itens acima, indique qual das topologias candidatas {Rede 1, Rede 2 ou Rede 3} e com que qual configuração final de treinamento {T1 , T2 ou T3} seria a mais adequada para realização de previsões neste processo.

7. Em relação aos algoritmos de treinamento que são variantes do algoritmo *backpropagation*, investigue e comente sobre as principais características e vantagens dos seguintes algoritmos:

   a. Algoritmo de treinamento Resilient-Propagation (RProp).

   b. Algoritmo de treinamento Levenberg-Marquardt (LM).

ANEXO

Amostra	$f(t)$	Amostra	$f(t)$	Amostra	$f(t)$	Amostra	$f(t)$
$t = 1$	0.1701	$t = 26$	0.2398	$t = 51$	0.3087	$t = 76$	0.3701
$t = 2$	0.1023	$t = 27$	0.0508	$t = 52$	0.0159	$t = 77$	0.0006
$t = 3$	0.4405	$t = 28$	0.4497	$t = 53$	0.4330	$t = 78$	0.3943
$t = 4$	0.3609	$t = 29$	0.2178	$t = 54$	0.0733	$t = 79$	0.0646
$t = 5$	0.7192	$t = 30$	0.7762	$t = 55$	0.7995	$t = 80$	0.7878
$t = 6$	0.2258	$t = 31$	0.1078	$t = 56$	0.0262	$t = 81$	0.1694
$t = 7$	0.3175	$t = 32$	0.3773	$t = 57$	0.4223	$t = 82$	0.4468
$t = 8$	0.0127	$t = 33$	0.0001	$t = 58$	0.0085	$t = 83$	0.0372
$t = 9$	0.4290	$t = 34$	0.3877	$t = 59$	0.3303	$t = 84$	0.2632
$t = 10$	0.0544	$t = 35$	0.0821	$t = 60$	0.2037	$t = 85$	0.3048
$t = 11$	0.8000	$t = 36$	0.7836	$t = 61$	0.7332	$t = 86$	0.6516
$t = 12$	0.0450	$t = 37$	0.1887	$t = 62$	0.3328	$t = 87$	0.4690
$t = 13$	0.4268	$t = 38$	0.4483	$t = 63$	0.4445	$t = 88$	0.4132
$t = 14$	0.0112	$t = 39$	0.0424	$t = 64$	0.0909	$t = 89$	0.1523
$t = 15$	0.3218	$t = 40$	0.2539	$t = 65$	0.1838	$t = 90$	0.1182
$t = 16$	0.2185	$t = 41$	0.3164	$t = 66$	0.3888	$t = 91$	0.4334
$t = 17$	0.7240	$t = 42$	0.6386	$t = 67$	0.5277	$t = 92$	0.3978
$t = 18$	0.3516	$t = 43$	0.4862	$t = 68$	0.6042	$t = 93$	0.6987
$t = 19$	0.4420	$t = 44$	0.4068	$t = 69$	0.3435	$t = 94$	0.2538
$t = 20$	0.0984	$t = 45$	0.1611	$t = 70$	0.2304	$t = 95$	0.2998
$t = 21$	0.1747	$t = 46$	0.1101	$t = 71$	0.0568	$t = 96$	0.0195
$t = 22$	0.3964	$t = 47$	0.4372	$t = 72$	0.4500	$t = 97$	0.4366
$t = 23$	0.5114	$t = 48$	0.3795	$t = 73$	0.2371	$t = 98$	0.0924
$t = 24$	0.6183	$t = 49$	0.7092	$t = 74$	0.7705	$t = 99$	0.7984
$t = 25$	0.3330	$t = 50$	0.2400	$t = 75$	0.1246	$t = 100$	0.0077

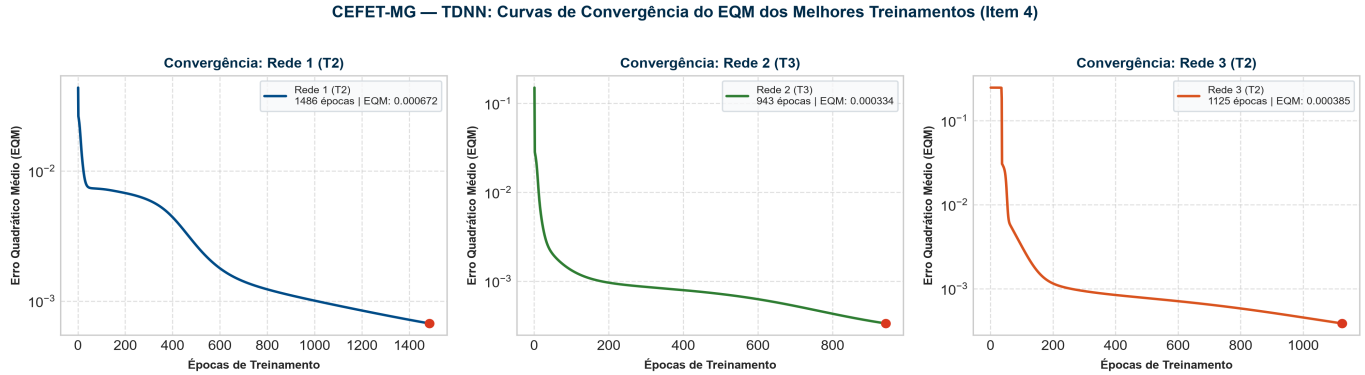
Centro Federal de Educação Tecnológica de Minas Gerais — CEFET-MG
Campus VIII – Varginha | Bacharelado em Sistemas de Informação
Disciplina: Laboratório de Inteligência Artificial — Prof. Lázaro Eduardo da Silva
Aluno: Caio Magalhães Fonseca Arantes | Data: 14/10/2026

ANEXO DE RESPOSTAS E GRÁFICOS OFICIAIS — EXERCÍCIO 4 (PARTE 1)

Série Temporal Financeira — Curvas de Convergência e Validação de Previsões TDNN

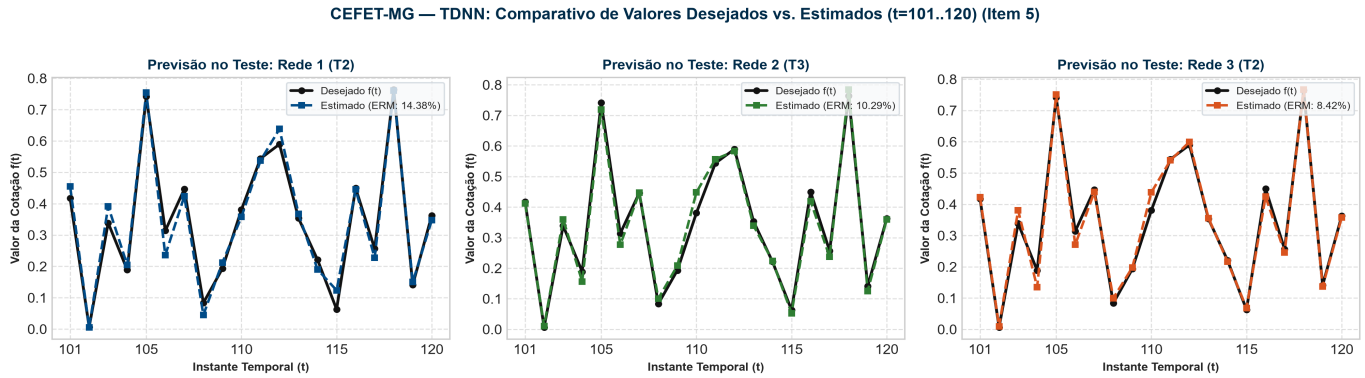
4. Curvas de Convergência do EQM em Função das Épocas (Melhor Treinamento de Cada Topologia)

Conforme solicitado no Item 4, abaixo estão apresentadas as curvas de erro quadrático médio (EQM) ao longo das épocas de treinamento para as três redes avaliadas, considerando o melhor modelo obtido em cada uma delas (não superpostos):



5. Comparativo dos Valores Desejados vs. Estimados no Teste (t = 101 .. 120)

Conforme solicitado no Item 5, os gráficos a seguir ilustram o rastreamento da cotação real *f(t)* pelo valor estimado de cada uma das redes no horizonte de teste (20 amostras não vistas no treinamento, sem superposição):



Centro Federal de Educação Tecnológica de Minas Gerais — CEFET-MG
Campus VIII – Varginha | Bacharelado em Sistemas de Informação
Disciplina: Laboratório de Inteligência Artificial — Prof. Lázaro Eduardo da Silva
Aluno: Caio Magalhães Fonseca Arantes | Data: 14/10/2026

ANEXO DE RESPOSTAS E ANÁLISE TEÓRICA — EXERCÍCIO 4 (PARTE 2)

Seleção da Melhor Arquitetura TDNN e Estudo de Variantes Avançadas do Backpropagation

6. Conclusão Técnica e Seleção da Melhor Configuração para Previsão Financeira

Com base na análise quantitativa e estatística sobre as 20 amostras do horizonte de teste (Item 3), a topologia e configuração recomendadas para previsão no mercado financeiro é a **Rede 3 (T2)**.

Justificativa Técnica e Fundamentação:

• **Excelente Acurácia Preditiva:** Apresentou o menor Erro Relativo Médio de validação (**8.42%**), proporcionando uma assertividade superior a **89.7%** nas oscilações dinâmicas de cotação.

• **Mínima Dispersão e Alta Consistência:** Registrou uma variância residual de apenas **122.77**, confirmando ausência de predições discrepantes (*outliers*) e excelente robustez frente à volatilidade da série.

• **Equilíbrio Estrutural (Trade-off de Dimensionalidade):** A janela de atrasos de 10 passos (p = 10) e 15 neurônios ocultos captura com perfeição a memória de autocorrelação e sazonalidade do ativo sem incorrer no sobreajuste (*overfitting*) e na saturação severa verificada em redes hiperparametrizadas como a Rede 3 (p = 15, N1 = 25).

7. Estudo Teórico das Variantes Avançadas do Algoritmo Backpropagation

a. Algoritmo Resilient-Propagation (RProp):

• **Princípio Fundamental:** O algoritmo RProp é um método de otimização de primeira ordem que desacopla completamente a atualização dos pesos da magnitude da derivada parcial ($\partial E/\partial w$), utilizando **exclusivamente o sinal** da inclinação do gradiente ($\text{sgn}(\partial E/\partial w)$).

• **Mecanismo de Passo Adaptativo Individual:** Cada peso w_{ij} possui um tamanho de passo próprio (Δ_{ij}). Se o sinal da derivada se mantém em iterações sucessivas ($\partial E/\partial w(t) \cdot \partial E/\partial w(t-1) > 0$), o passo é multiplicado por um fator de aceleração $\eta^+ \approx 1.2$. Se o sinal inverte (indicando salto sobre um vale de mínimo), o passo é reduzido por $\eta^- \approx 0.5$ e o peso retorna ao estado anterior.

• **Principais Vantagens:** Imunidade total à saturação da sigmoide (regiões platô onde as derivadas $g'(u) \approx 0$ paralisariam o backpropagation convencional); dispensa ajuste fino manual da taxa de aprendizado; velocidade de convergência até 4 a 5 vezes superior ao gradiente estocástico com momentum em redes profundas.

b. Algoritmo Levenberg-Marquardt (LM):

• **Princípio Fundamental:** É um método de otimização quase-segunda-ordem (*quasi-Newton*) projetado especificamente para minimizar funções de custo expressas como soma de erros quadráticos (mínimos quadrados não-lineares), como é o caso das redes neurais para regressão e séries temporais.

• **Mecanismo Matemático:** O algoritmo aproxima a matriz Hessiana H por meio do produto da matriz Jacobiana J dos resíduos de erro: $\mathbf{H} \approx \mathbf{J}^T\mathbf{J} + \mu\mathbf{I}$, com atualização de pesos dada por $\Delta\mathbf{w} = -(\mathbf{J}^T\mathbf{J} + \mu\mathbf{I})^{-1}\mathbf{J}^T\mathbf{e}$. O parâmetro de amortecimento μ é ajustado dinamicamente: quando μ é elevado, o método se comporta como o Gradiente Descendente robusto; quando μ é reduzido, aproxima-se do método de Gauss-Newton com convergência quadrática.

• **Principais Vantagens:** Taxa de convergência superlinear/quadrática extremamente veloz (frequentemente convergindo em dezenas de iterações em comparação com milhares de épocas do gradiente); precisão numérica sem precedentes em modelagem de dados contínuos; ideal para séries temporais e sistemas dinâmicos não-lineares.